



École nationale
de la statistique
et de l'analyse
de l'information

PROJET STATISTIQUE 2EME ANNEE

DÉTECTION DE LA DIFFUSION INAUTHENTIQUE D'IMAGES SUR LES RÉSEAUX SOCIAUX

Rapport de projet statistique

Groupe 21 :

Djamal Y. TOE

Ousseynou SIMAL

Louise PECH-POULIQUEN

Encadrant :

Erwan LE NAGARD

Responsable du projet :

Brandon SAINTILAN

Table des matières

Remerciements	ii
Résumé	iii
Abstract	iv
Liste des sigles et abréviations	vii
1 Introduction générale	1
1.1 Diffusion de désinformation visuelle sur les réseaux sociaux et la viralité du récit “C’est Nicolas qui paie” sur X	1
1.2 Objectifs de l’étude : détecter la diffusion coordonnée d’images	2
1.3 Hypothèses de recherche	2
2 Données et méthodologie d’analyse de la diffusion d’images	3
2.1 Stratégie méthodologique pour détecter la diffusion inauthentique	3
2.2 Définition des concepts clés : coordination, amplification et inauthenticité	4
2.3 Description du jeu de données collecté sur X	5
2.4 Identification des images similaires et regroupement thématique	6
2.5 Construction et validation du réseau de coordination entre comptes X	11
2.6 Outils et normes de présentation	17
3 Résultats : dynamiques de diffusion du récit “C’est Nicolas qui paie”	18
3.1 Structuration et dynamiques des corpus d’images et de tweets : clustering, engagement et thématiques	18
3.2 Structure des interactions entre comptes utilisateurs	22
3.3 Analyse des réseaux de diffusion des images	25
4 Discussions	32
4.1 Synthèse de l’étude	32
4.2 Validité et apports de l’approche	33
4.3 Forces de la méthodologie	33
4.4 Limites	34
4.5 Perspectives	34
5 Conclusion générale	35
5.1 Résultat principal de l’étude	35
5.2 Utilisations et Applications pratiques	35
5.3 Recommandations	35
6 Liste des références	37
A Annexes	ix

REMERCIEMENTS

Nous tenons à exprimer notre profonde gratitude à notre encadrant de projet pour la proposition de ce sujet, particulièrement stimulant, qui nous a permis d'explorer des problématiques riches et d'acquérir de nouvelles compétences méthodologiques.

Nous le remercions également pour la qualité de son accompagnement tout au long du projet, ainsi que pour ses retours réguliers, ses conseils avisés et ses recommandations, toujours clairs et constructifs, qui ont grandement contribué à la progression de nos travaux.

Nous adressons nos remerciements à la Direction des Systèmes d'Information (DSI) pour la mise à disposition des ressources de stockage nécessaires, notamment le disque dur ayant permis l'exportation et la manipulation des volumes importants de données images.

Nous remercions sincèrement Mme Myriam Vimond pour son accompagnement, sa disponibilité et ses éclaircissements concernant les procédures de tests multiples ainsi que les méthodes basées sur les permutations.

Nous exprimons également notre reconnaissance à M. Da Veiga pour le temps qu'il nous a accordé ainsi que pour ses conseils précieux relatifs aux algorithmes de clustering et aux méthodes de réduction de dimension.

Nos remerciements s'adressent également à M. Basile Deloynes pour ses pistes de réflexion pertinentes, notamment en ce qui concerne certaines pistes de clustering et l'utilisation du logiciel Gephi.

Nous remercions par ailleurs l'ensemble du corps enseignant et du personnel administratif pour la qualité de l'enseignement dispensé, leur disponibilité ainsi que leur accompagnement tout au long de la formation.

Enfin, nous souhaitons nous remercier collectivement pour notre engagement, notre implication et notre capacité à travailler de manière constructive en équipe. Malgré quelques désaccords ponctuels, nous avons su préserver un esprit de coopération et progresser ensemble tout au long de la réalisation du projet.

RÉSUMÉ

L'essor des réseaux sociaux a profondément transformé les dynamiques de diffusion de l'information, en facilitant à la fois la circulation de contenus et l'émergence de stratégies de manipulation informationnelle. Parmi celles-ci, les comportements inauthentiques coordonnés jouent un rôle central, en permettant l'amplification artificielle de certains messages via la synchronisation d'actions entre comptes.

Dans ce contexte, cette étude analyse la diffusion de l'expression « C'est Nicolas qui paie » sur le réseau social X en 2025, rapidement devenue virale. L'objectif est de déterminer si sa viralité repose sur une dynamique organique ou sur des comportements inauthentiques coordonnés, définis comme des pratiques visant à manipuler la visibilité et la circulation des contenus.

Nous exploitons un corpus de publications récoltées de janvier à novembre 2025. L'attention est portée sur la circulation des images de ces publications, susceptibles d'être diffusées de manière répétée et synchronisée. Nous mobilisons des méthodes combinant similarités visuelle et sémantique des images, dynamiques temporelles et analyse de réseaux. Plus précisément, nous utilisons d'abord le modèle CLIP pour vectoriser les images. Les représentations sont ensuite réduites avec UMAP puis regroupées via l'algorithme de HDBSCAN pour le clustering visuel et sémantique, avec une optimisation bayésienne pour le réglage des hyperparamètres. A partir des résultats de clusters, nous établissons des réseaux, reliant les comptes qui diffusent des contenus proches selon une composante temporelle. La structure de ces réseaux est ensuite analysée via l'algorithme de Louvain, afin d'identifier des communautés de comptes, et validée statistiquement, avec notamment des modèles nuls par permutation et des tests multiples.

Cela nous permet enfin d'analyser les structures de diffusion des images et leur synchronisation dans le temps. Nous pouvons alors détecter des schémas de coordination, d'identifier des amplifications artificielles et de caractériser les structures de diffusion associées aux comportements inauthentiques. Nous avons ainsi détecté des comportements inorganiques au sein du dataset, reposant sur des proximités visuelles et temporelles significatives, validées statistiquement. L'analyse en communautés révèle notamment l'existence de groupes de comptes aux rôles différenciés, avec par exemple une communauté initiatrice associée à « NicolasQuiPaie », distincte de communautés relais participant à la diffusion du contenu. Certains résultats ne peuvent toutefois pas permettre de conclure de manière certaine à l'inauthenticité des comportements, mais présentent tout de même des niveaux de suspicion non négligeables, compatibles avec des mécanismes de coordination.

Mots clés : *Diffusion inauthentique, comportements coordonnés, propagation d'images, similarité visuelle et sémantique, dynamique temporelle, réseaux sociaux, détection de communautés, CLIP, UMAP, HDBSCAN, optimisation bayésienne, algorithme de Louvain*

ABSTRACT

The rise of social media has profoundly transformed the dynamics of information diffusion, facilitating both the circulation of content and the emergence of information manipulation strategies. Among these, coordinated inauthentic behaviors play a central role by enabling the artificial amplification of certain messages through the synchronization of actions across accounts.

In this context, this study analyzes the spread of the “C’est Nicolas qui paie” narrative on the social media platform X in 2025, which rapidly became viral. The objective is to determine whether its virality results from organic dynamics or from coordinated inauthentic behaviors, defined as practices aimed at manipulating content visibility and circulation.

We analyze a dataset of posts collected between January and November 2025. Particular attention is given to the circulation of images within these posts, which may be repeatedly and synchronously shared. We employ methods combining visual and semantic similarity of images, temporal dynamics, and network analysis.

More specifically, we first use the CLIP model to vectorize the images. The resulting representations are then reduced using UMAP and clustered using the HDBSCAN algorithm for visual and semantic grouping, with Bayesian optimization used to tune hyperparameters. Based on these clusters, we construct networks linking accounts that share similar content, incorporating a temporal component. The structure of these networks is then analyzed using the Louvain algorithm to identify communities of accounts, and statistically validated using permutation-based null models and multiple testing procedures.

This approach allows us to analyze the diffusion structures of images and their temporal synchronization. We are thus able to detect coordination patterns, identify artificial amplification, and characterize diffusion structures associated with inauthentic behaviors. We detect inauthentic signals within the dataset, based on significant visual and temporal proximity, supported by statistical validation. Community detection further reveals groups of accounts with differentiated roles, including for instance an initiating community associated with “NicolasQuiPaie”, distinct from relay communities involved in content propagation. While some results do not allow us to conclusively establish inauthentic behavior, they nonetheless exhibit non insignificant levels of suspicion consistent with coordinated mechanisms.

Keywords : *Inauthentic diffusion, coordinated behaviors, image propagation, visual and semantic similarity, temporal dynamics, social networks, community detection, CLIP, UMAP, HDBSCAN, Bayesian optimization, Louvain algorithm*

LISTE DES SIGLES ET ABRÉVIATIONS

API	Application Programming Interface (interface de programmation d'application).
CAF	Caisse d'Allocations Familiales.
CLIP	Contrastive Language-Image Pretraining.
DBCV	Density-Based Clustering Validation.
DBSCAN	Density-Based Spatial Clustering of Applications with Noise.
FDR	False Discovery Rate.
FWER	Family-Wise Error Rate.
HDBSCAN	Hierarchical Density-Based Spatial Clustering of Applications with Noise.
MC	Monte-Carlo.
MST	Minimum Spanning Tree (arbre couvrant minimal).
PCA	Principal Components Analysis.
UMAP	Uniform Manifold Approximation and Projection.

1 INTRODUCTION GÉNÉRALE

1.1 DIFFUSION DE DÉSINFORMATION VISUELLE SUR LES RÉSEAUX SOCIAUX ET LA VIRALITÉ DU RÉCIT “C’EST NICOLAS QUI PAIE” SUR X

Depuis les années 2000, l’essor des réseaux sociaux a transformé la circulation de l’information. Des plateformes comme X (anciennement Twitter), Facebook ou Instagram permettent une diffusion quasi instantanée auprès de millions d’utilisateurs. Si cela facilite l’accès à l’information, cela favorise aussi la désinformation à grande échelle (Ruffo et al. 2023).

La diffusion des informations, véridiques ou non, est influencée par les mécanismes algorithmiques des plateformes et la structure en réseaux interconnectés. La désinformation affecte les débats publics, les comportements collectifs et les processus électoraux (Ruffo et al. 2023). Parmi les mécanismes documentés, les comptes automatisés (*social bots*) peuvent amplifier artificiellement certains messages (Stella, Ferrara, and De Domenico 2018). La manipulation ne repose pas uniquement sur l’automatisation : des comportements coordonnés, impliquant comptes humains ou bots, maximisent la portée de contenus similaires dans des temporalités rapprochées, phénomène appelé *coordinated inauthentic behavior* (Murero 2023).

Ces stratégies se retrouvent dans divers contextes, de la désinformation COVID-19 aux campagnes politiques (Cinelli et al. 2022). Les contenus visuels, images et mèmes, sont particulièrement efficaces pour la viralité, car facilement modifiables tout en conservant le message (Wohlert et al. 2025 ; Nizzoli et al. 2021). Avec l’émergence de l’IA générative, distinguer diffusion organique et manipulation devient de plus en plus difficile.

C’est dans ce contexte que l’expression « C’est Nicolas qui paie » est apparue début 2025 sur X. Nicolas, personnage fictif, contribuable français trentenaire gagnant bien sa vie, est exaspéré de voir son revenu durement accumulé partir en diverses taxes, impôts et prélèvements. Rapidement diffusé et repris par différents comptes, notamment de sphères d’extrême droite, jusqu’à finir à l’Assemblée nationale (discours du député UDR des Bouches-du-Rhône, Gérauld Varny), le personnage de Nicolas, et les différents acolytes l’accompagnant (Chantal et Bernard les retraités, Karim sans-emploi), reprennent et permettent d’amplifier la diffusion d’idéologies contestataires, ouvertement racistes, rejetant l’immigration et la solidarité intergénérationnelle, sous couvert de dénonciation d’un ras-le-bol fiscal (Le Nouvel Obs 2025). Son appropriation rapide soulève des questions sur les mécanismes de propagation à l’œuvre. Cette étude cherche ainsi à déterminer si la diffusion de l’expression relève de dynamiques organiques ou bien de coordination inauthentique, et si oui dans quelle mesure.

1.2 OBJECTIFS DE L'ÉTUDE : DÉTECTER LA DIFFUSION COORDONNÉE D'IMAGES

L'objectif principal est de détecter la diffusion inauthentique d'images liées au syntagme "C'est Nicolas qui paie" sur X. Les objectifs secondaires sont :

- Analyser la coordination des publications selon la similarité visuelle et la proximité temporelle ;
- Identifier les contenus bénéficiant d'une amplification artificielle, avec engagement anormalement élevé ;
- Détecter les opérations structurées, c'est-à-dire la propagation coordonnée d'images au sein de clusters d'utilisateurs.

1.3 HYPOTHÈSES DE RECHERCHE

Dans le prolongement des objectifs définis, les hypothèses de recherche suivantes sont posées :

- **Hypothèse 1 :** La diffusion des images présente des schémas temporels non aléatoires, révélant des comportements coordonnés.
- **Hypothèse 2 :** Certaines images visuellement similaires ont bénéficié d'une amplification artificielle.
- **Hypothèse 3 :** La propagation des images s'organise autour de communautés distinctes de comptes, avec des mécanismes propres à chaque groupe.

2 DONNÉES ET MÉTHODOLOGIE D'ANALYSE DE LA DIFFUSION D'IMAGES

2.1 STRATÉGIE MÉTHODOLOGIQUE POUR DÉTECTER LA DIFFUSION INAUTHENTIQUE

Cette étude analyse la diffusion d'images sur la plateforme X entre janvier et novembre 2025 afin d'identifier d'éventuels mécanismes de coordination et d'amplification entre comptes utilisateurs. Elle repose sur une approche combinant vision par ordinateur, représentations sémantiques d'images, analyse de réseaux et inférence statistique. Comme illustré dans la figure 1, l'analyse suit un pipeline allant du traitement des images à l'inférence statistique. Les images sont d'abord prétraitées afin de détecter et fusionner les doublons ou quasi-doublons. Elles sont ensuite vectorisées à l'aide du modèle Contrastive Language-Image Pretraining (CLIP), produisant des représentations de dimension 512 capturant leur contenu visuel et sémantique.

Ces représentations sont projetées avec Uniform Manifold Approximation and Projection (UMAP), puis regroupées via Hierarchical Density-Based Spatial Clustering of Applications with Noise (HDBSCAN) afin d'identifier des ensembles d'images similaires. Un réseau est ensuite construit en reliant les comptes ayant diffusé des images appartenant aux mêmes clusters.

Enfin, des tests de permutation avec correction pour comparaisons multiples permettent d'identifier les relations significatives et d'extraire la structure principale du réseau.

Ce pipeline permet ainsi de passer d'images brutes à une représentation structurée des interactions entre comptes, facilitant l'identification de comportements potentiellement coordonnés.




FIGURE 1 – Pipeline méthodologique pour la détection de coordination dans la diffusion d'images sur X

2.2 DÉFINITION DES CONCEPTS CLÉS : COORDINATION, AMPLIFICATION ET INAUTHENTICITÉ

Afin de clarifier le cadre d'analyse, nous définissons les principaux concepts utilisés dans cette étude :

- **X** : plateforme de réseau social permettant de publier et partager de courts contenus (anciennement Twitter, renommée X en 2023 après son rachat par Elon Musk).
- **Coordination** : actions menées de manière organisée ou synchronisée par plusieurs acteurs, sans nécessairement impliquer une intention trompeuse (par exemple des mobilisations citoyennes) (Nizzoli et al. 2021 ; Wohler et al. 2025).
- **Amplification** : propagation rapide et fortement engagée de contenus identiques ou similaires entre plusieurs comptes (Wohler et al. 2025).
- **Opérations structurées** : campagnes planifiées dans lesquelles des groupes de comptes diffusent de manière coordonnée un même contenu (Wohler et al. 2025).
- **Inauthenticité** : comportements trompeurs ou manipulateurs, tels que l'usage de faux comptes ou la dissimulation d'intentions. Elle peut exister indépendamment de la coordination et reste difficile à détecter (Nizzoli et al. 2021).
- **Réseau de comptes** : représentation des relations entre comptes basée sur leurs comportements de diffusion. Dans la figure 2, les nœuds correspondent aux comptes, leur taille reflète leur importance structurelle, les arêtes l'intensité des interactions, et les couleurs les communautés comportementales.¹




FIGURE 2 – Exemple de réseau de comptes

1. Le poids des arêtes correspond à la somme des contributions $e^{-\lambda \Delta t}$ pour chaque co-publication, cf. section 2.5.1.

2.3 DESCRIPTION DU JEU DE DONNÉES COLLECTÉ SUR X

Les données utilisées ont été collectées sur la plateforme X, avec le syntagme *Nicolas qui paie* [*nicolasquipaie* OR *#nicolasquipaie* OR *"nicolas qui paie"* OR *juliequipaie* OR *@ nicolasquipaie* OR *#JeSuisNicolas* OR *from :nicolasquipaie* OR *to :nicolasquipaie*]. Elles décrivent la diffusion d'images à travers les comptes utilisateurs et le temps. Chaque observation correspond à une publication d'image par un utilisateur à un instant donné.

Formellement, on considère un ensemble de N observations définies par les triplets :

$$X_i = (u_i, I_i, t_i), \quad i = 1, \dots, N$$

où u_i désigne l'utilisateur, I_i l'image publiée et t_i le temps de publication.

Un même utilisateur peut apparaître plusieurs fois, de même qu'une image peut être diffusée par plusieurs comptes.

Ces données peuvent être représentées sous forme matricielle :

$$X = \begin{pmatrix} u_1 & I_1 & t_1 \\ u_2 & I_1 & t_2 \\ u_1 & I_3 & t_3 \\ \vdots & \vdots & \vdots \\ u_i & I_j & t_N \end{pmatrix}$$

où chaque ligne correspond à une publication.

On note U l'ensemble des utilisateurs, I l'ensemble des images et P l'ensemble des publications.

Chaque utilisateur est associé à des informations telles que son identifiant, son nom, ainsi que des métriques d'activité (nombre d'abonnés, de suivis, etc.).

Chaque image est représentée par un vecteur sémantique de dimension 512 obtenu via le modèle CLIP, et sera associée, après clustering, à un cluster $c \in C$.

Enfin, chaque publication contient, en plus du triplet (u_i, I_i, t_i) , des informations complémentaires telles que le type de publication (original, commentaire, repartage), la source éventuelle, ainsi que des indicateurs d'engagement (likes, vues, etc.).

2.4 IDENTIFICATION DES IMAGES SIMILAIRES ET REGROUPEMENT THÉMATIQUE

2.4.1 Détection des images dupliquées par perceptual hashing

La détection des images dupliquées repose sur des méthodes de *perceptual hashing*, qui consistent à générer une empreinte numérique à partir du contenu visuel d'une image. Des images visuellement proches produisent ainsi des empreintes similaires, même après des transformations mineures telles que la compression², les variations de luminosité ou les corrections de couleur (Samanta and Jain 2021).

Ces méthodes sont couramment utilisées pour la détection de duplications, la modération de contenu ou la recherche d'images inversées. Parmi les approches les plus répandues figurent **pHash**, **wHash**, ainsi que **aHash** et **dHash**, basées respectivement sur l'intensité moyenne des pixels et sur les variations locales entre pixels.

Dans cette étude, les paramètres du modèle (choix de l'algorithme et seuil de similarité) sont optimisés afin de limiter les faux positifs, c'est-à-dire éviter de considérer comme identiques des images distinctes. La méthode retenue est celle minimisant ce taux d'erreur, afin de garantir la qualité des regroupements (cf. figure 3).




FIGURE 3 – Processus de regroupement des images exactes ou quasi-exactes avec le perceptual hashing

2.4.2 Représentation sémantique des images avec CLIP

Le *perceptual hashing* permet d'identifier des images visuellement proches, mais reste limité face à des transformations plus complexes, telles que l'ajout ou la suppression d'éléments (Samanta and Jain 2021).

Pour dépasser cette limite, les images sont ensuite vectorisées à l'aide du modèle CLIP, produisant des embeddings³ de dimension 512. Ce modèle projette images et textes dans un même espace, permettant de capturer non seulement des similarités visuelles, mais également des relations sémantiques.

2. Par exemple la compression JPEG, qui modifie légèrement les pixels sans altérer significativement la perception visuelle.

3. Un embedding est une représentation vectorielle d'un objet (ici une image) dans un espace de dimension fixe, de sorte que des objets similaires soient proches les uns des autres selon une mesure de distance.

Le principe de ce modèle est illustré dans la figure 4, qui montre comment CLIP est entraîné en associant des images à leurs descriptions textuelles. Cette phase d'apprentissage permet d'aligner les représentations visuelles et textuelles dans un espace commun.

Dans le cadre du *zero-shot encoding*, chaque image peut ainsi être comparée à des descriptions textuelles correspondant à différentes catégories (par exemple : même humoristique, contenu politique ou informatif), sans nécessiter d'entraînement supplémentaire (Radford et al. 2021).

Cette approche est particulièrement adaptée à l'analyse de contenus complexes comme les mèmes, car elle permet d'identifier des proximités conceptuelles au-delà des simples ressemblances visuelles. Elle offre ainsi une représentation plus riche que des modèles purement visuels (*Dinov2, Dinov3, ect.*).




FIGURE 4 – Illustration du processus d'entraînement et d'utilisation du modèle CLIP pour la prédiction zero-shot. Source : Radford et al. (2021)

2.4.3 Réduction de dimension des embeddings par UMAP

Les embeddings produits par CLIP sont projetés dans un espace de dimension réduite à l'aide de UMAP⁴. Cette méthode construit un graphe de voisinage dans l'espace d'origine (ici 512 dimensions), puis apprend une représentation de plus faible dimension préservant les relations locales entre observations (Sainburg, McInnes, and Gentner 2021 ; McInnes, Healy, and Melville 2018).

Comme illustré dans la figure 5 (extraite du site de [BIOSTATSQUID](#)), cette projection permet de représenter des données complexes dans un espace plus compact tout en conservant leur structure de voisinage. Elle facilite ainsi l'identification de groupes d'images similaires.

Le comportement de l'algorithme est principalement contrôlé par trois paramètres : le nombre de voisins (*n_neighbors*), qui équilibre structure locale et globale, la distance minimale (*min_dist*), qui influence la compacité des groupes, et la métrique (*metric*) utilisée pour mesurer la similarité entre observations.

4. Méthode de réduction de dimension non linéaire préservant les relations de voisinage locales dans les données.

Dans ce contexte, UMAP est particulièrement adapté car il capture des structures non linéaires et préserve efficacement les relations de voisinage, ce qui est essentiel pour regrouper des images sémantiquement proches avant l'étape de clustering.




FIGURE 5 – Processus de reductions de dimensions avec UMAP - Source : biostatsquid

2.4.4 Regroupement des images similaires avec HDBSCAN

HDBSCAN est un algorithme de clustering basé sur la densité⁵ qui étend Density-Based Spatial Clustering of Applications with Noise (DBSCAN) afin de détecter des *clusters de densités variables* en construisant une *hiérarchie de clusters*.

L'algorithme utilise la *distance de mutual reachability*, définie pour deux points x_p et x_q par :

$$d_{mreach}(x_p, x_q) = \max(d_{core}(x_p), d_{core}(x_q), d(x_p, x_q))$$

où $d(x_p, x_q)$ est la distance classique entre deux points, et $d_{core}(x)$ est la *core distance*, correspondant à la distance entre le point x et son k -ième plus proche voisin, ce qui permet de caractériser la densité locale : plus cette distance est faible, plus la zone est dense (Malzer and Baum 2020).

A partir de ces distances, HDBSCAN construit un Minimum Spanning Tree (arbre couvrant minimal) (MST), puis une hiérarchie de clusters. La sélection finale repose sur la *stabilité des clusters*, définie par :

$$S(C_i) = \sum_{x_j \in C_i} (\lambda_{\max}(x_j, C_i) - \lambda_{\min}(C_i)), \quad \lambda = \frac{1}{\varepsilon}$$

où ε correspond à une échelle de distance (liée à la distance de *mutual reachability*), et :

— $x_j \in C_i$ désigne les points du cluster C_i ;

5. En clustering, la densité désigne la concentration de points dans une région de l'espace. Elle est généralement estimée à partir du nombre de voisins dans un rayon donné ou de la distance aux plus proches voisins.

- $\lambda_{\min}(C_i)$ est la valeur de λ à laquelle le cluster apparaît dans la hiérarchie ;
- $\lambda_{\max}(x_j, C_i)$ est la valeur maximale de λ pour laquelle le point x_j reste dans ce cluster.

Ainsi, la stabilité mesure la persistance d'un cluster à travers différentes échelles de densité : les clusters les plus stables sont retenus, tandis que les points n'appartenant à aucun cluster stable sont considérés comme du *bruit*.

Pour évaluer la qualité du clustering, on utilise l'indice Density-Based Clustering Validation (DBCV) :

$$\text{DBCV} = \frac{1}{N} \sum_{i=1}^K \sum_{x \in C_i} \frac{S(i) - D(i, x)}{S(i)}$$

où $S(i)$ mesure la séparation entre clusters et $D(i, x)$ la dispersion intra-cluster du point x . Cet indice permet d'évaluer simultanément la compacité et la séparation des clusters.

Le comportement de HDBSCAN dépend de plusieurs hyperparamètres. Parmi les plus importants, *min_cluster_size* définit la taille minimale d'un cluster et contrôle la granularité des regroupements, tandis que *min_samples* influence la sensibilité à la densité et donc la détection du bruit. La métrique de distance utilisée doit être cohérente avec celle employée pour les embeddings. Enfin, *cluster_method* détermine la manière dont les clusters sont extraits à partir de la hiérarchie de densité, ce qui peut affecter à la fois la finesse et la stabilité des regroupements. Le choix de ces paramètres permet d'ajuster le compromis entre détection de petits groupes d'images et robustesse des clusters identifiés.

Contrairement à des méthodes comme les **k-means** ou la classification hiérarchique, HDBSCAN ne nécessite pas de spécifier le nombre de clusters, peut détecter des formes et des densités arbitraires, et identifie automatiquement les points considérés comme bruit. Associé à DBCV, il est particulièrement adapté aux embeddings d'images.

Comme illustré dans la figure 6, ce processus permet de passer d'un nuage de points (projeté via UMAP) à une structuration en clusters, tout en identifiant les observations isolées. Les différentes visualisations mettent en évidence la densité des données, la formation des clusters et leur stabilité.




FIGURE 6 – Illustration simplifiée du processus de clustering HDBSCAN : des données brutes à l'identification des clusters et du bruit

2.4.5 Optimisation des hyperparamètres par optimisation bayésienne

La figure 7 (*Sources des images : Daily Dose of Data Science (2023) ; Lehigh University (n.d.)*) illustre le processus d'optimisation bayésienne utilisé pour le réglage des hyperparamètres de UMAP et HDBSCAN. Le vecteur des hyperparamètres :

$$x = (n_{\text{neighbors}}, n_{\text{components}}, \text{min_dist}, \text{min_cluster_size}, \text{min_samples}, \text{cluster_method})$$

est optimisé afin d'identifier la configuration :

$$x^* = \arg \min_{x \in \mathcal{X}} f(x), \quad f(x) = -\text{DBCV}(\text{HDBSCAN}(\text{UMAP}(D; x))),$$

où D correspond aux embeddings d'images produits par CLIP. Le signe négatif transforme la maximisation de l'indice DBCV en problème de minimisation. Le premier graphique montre le **cycle de recherche des hyperparamètres**, où le modèle substitut est entraîné sur les données existantes pour proposer de nouveaux hyperparamètres à tester, puis mis à jour itérativement selon les résultats obtenus.

Le second graphique illustre le compromis **exploration/exploitation**. L'algorithme explore différentes zones de l'espace des hyperparamètres tout en se concentrant progressivement sur les régions prometteuses où les performances sont meilleures. La procédure détaillée est présentée en annexe (cf. section A.9).




FIGURE 7 – Processus de l'optimisation bayésienne

2.5 CONSTRUCTION ET VALIDATION DU RÉSEAU DE COORDINATION ENTRE COMPTES X

2.5.1 Construction du réseau de coordination temporelle

L'objectif est d'identifier les relations de coordination entre les comptes ayant publié des images appartenant à un même cluster. Cette coordination est mesurée à partir de la proximité temporelle entre les publications. Considérons l'ensemble des images d'un cluster I_{c^*} . Pour deux comptes u et v ayant publié une même image i , on définit la différence temporelle :

$$\Delta t_{uv,i} = |t_{u,i} - t_{v,i}|$$

où $t_{u,i}$ et $t_{v,i}$ correspondent aux instants de publication de l'image i par les comptes u et v .

Afin de quantifier l'intensité de la coordination, chaque co-publication est pondérée par une fonction décroissante de la distance temporelle :

$$w_{uv,i} = e^{-\lambda \Delta t_{uv,i}}$$

Le paramètre λ contrôle la vitesse de décroissance : une valeur élevée privilégie les publications très proches dans le temps, tandis qu'une valeur plus faible produit un réseau plus dense en intégrant des décalages temporels plus importants.

Le poids total de coordination entre deux comptes est obtenu en agrégeant ces contributions sur l'ensemble des images du cluster :

$$W_{uv}^{(c^*)} = \sum_{i \in I_{c^*}} e^{-\lambda \Delta t_{uv,i}}$$

On construit ainsi un graphe pondéré :

$$G_{c^*} = (U_{c^*}, E_{c^*}, W^{(c^*)})$$

où U_{c^*} désigne les comptes ayant publié des images du cluster, et E_{c^*} les relations (les arêtes) de coordination entre eux.

Ce poids agrégé capture simultanément la fréquence de co-publication, la proximité temporelle et l'intensité potentielle de coordination comportementale.

2.5.2 Choix des valeurs du paramètre λ

Afin d'analyser la sensibilité du modèle à la décroissance temporelle, plusieurs valeurs de λ sont considérées :

$$\lambda \in \{0.05, 0.10, 0.20, 0.30, 0.40, 0.50\}$$

Ce paramètre détermine l'échelle temporelle à laquelle la coordination est détectée. Une valeur élevée (par exemple $\lambda = 0.50$) privilégie des publications quasi simultanées, tandis qu'une valeur plus faible (par exemple $\lambda = 0.05$) permet de capturer des coordinations plus étalées dans le temps.

L'analyse de ces différentes valeurs permet d'évaluer la robustesse des structures détectées et d'identifier les échelles temporelles pertinentes de coordination.

2.5.3 Test statistique des co-publications par permutations

2.5.3.1 Modèle statistique

Chaque publication d'image appartenant à un cluster c^* est représentée par un triplet :

$$X_i = (u_i, I_i, t_i), \quad i = 1, \dots, N$$

où u_i est le compte utilisateur, I_i l'identifiant de l'image et t_i le temps de publication. L'ensemble des données est noté $X = (X_1, \dots, X_N)$.

L'objectif est de détecter si deux comptes u et v présentent un comportement coordonné dans la publication des images du cluster c^* .

2.5.3.2 Statistique de test

Pour une paire de comptes (u, v) , on définit la statistique (cf. section 2.5.1) :

$$W_{uv} = \sum_{i \in I_{c^*}} e^{-\lambda |t_{u,i} - t_{v,i}|}$$

Cette statistique mesure l'intensité de la coordination temporelle : les publications proches dans le temps contribuent fortement, tandis que les publications éloignées contribuent faiblement.

2.5.3.3 Hypothèses statistiques

On teste :

- **Hypothèse nulle** H_0 : conditionnellement à chaque image, les temps de publication sont indépendants des comptes
- **Hypothèse alternative** H_1 : certains comptes publient les mêmes images dans des intervalles de temps anormalement courts

2.5.3.4 Principe du test de permutation

Pour évaluer la significativité de W_{uv} , on génère des jeux de données alternatifs en permutant les **temps de publication conditionnellement à chaque image** :

$$(t_{u_1,i}, t_{u_2,i}, \dots, t_{u_{n_i},i}) \longrightarrow (t_{\pi(u_1),i}, t_{\pi(u_2),i}, \dots, t_{\pi(u_{n_i}),i})$$

où π est une permutation des comptes ayant publié l'image i .

Cette permutation locale repose sur l'hypothèse d'échangeabilité : sous H_0 , les temps de publication associés à une image sont invariants par permutation des comptes. Elle permet de préserver la structure temporelle propre à chaque image (tendances, saisonnalité), contrairement à une permutation globale qui détruirait cette structure.

Pour chaque permutation π_b , $b = 1, \dots, B$, on calcule :

$$W_{uv}^{(b)} = \sum_{i \in I_{c^*}} e^{-\lambda |t_{u,i}^{(b)} - t_{v,i}^{(b)}|}$$

Sous H_0 , la statistique observée doit être compatible avec la distribution des $W_{uv}^{(b)}$. Une valeur significativement plus élevée que celle que l'on observe habituellement sous H_0 indique une coordination temporelle.

2.5.3.5 Calcul de la p-value

La p-value empirique est définie par :

$$\hat{p}_B = \frac{1 + \sum_{b=1}^B \mathbf{1}(W_{uv}^{(b)} \geq W_{uv})}{B + 1}$$

La règle de décision est alors :

$$\text{Rejeter } H_0 \quad \text{si} \quad \hat{p}_B < \alpha$$

où $\alpha \in \{0,5, 0,6\}$ est le seuil de significativité.

Cette approche permet de détecter des liens significatifs tout en respectant la variabilité naturelle des temps de publication et la structure propre à chaque image.

2.5.4 Correction des tests multiples et extraction du sous-réseau significatif

Pour un cluster contenant n comptes, le nombre de tests effectués est :

$$m = \frac{n(n-1)}{2}$$

Sans correction, le nombre attendu de faux positifs est $E[V] = m\alpha$.

Afin de contrôler ce phénomène, nous utilisons la False Discovery Rate (FDR) avec la procédure de Benjamini-Hochberg, qui permet de limiter la proportion de faux positifs tout en conservant un bon pouvoir de détection ($FDR \leq \alpha$) ([Shuken and McNerney 2021](#)).

La FDR est définie par :

$$FDR = \mathbb{E}\left(\frac{V}{R}\right)$$

où V est le nombre de faux positifs et R le nombre total d'hypothèses rejetées.

Cette approche permet de trouver un compromis entre détection et fiabilité, et est particulièrement adaptée dans un contexte de réseaux comportant un grand nombre de tests.

Le sous-réseau statistiquement significatif est alors défini par :

- **Nœus** : comptes $u \in U$
- **Arêtes** : paires de comptes avec p_{uv} significatif après correction
- **Poids** : $W_{uv}^{(c^*)}$

Ce sous-réseau représente les relations de coordination temporelle robustes détectées dans le cluster.

2.5.5 Détection de communautés dans les réseaux de diffusion

L'algorithme de Louvain est appliqué afin de détecter des communautés de comptes présentant des comportements de diffusion similaires, comme l'ont fait Wohler et al. (2025) et Nizzoli et al. (2021).

Ce choix repose sur plusieurs propriétés particulièrement adaptées à notre contexte. Tout d'abord, Louvain permet d'optimiser efficacement la modularité sur des graphes de grande taille, ce qui le rend particulièrement pertinent pour l'analyse de réseaux de diffusion comportant un grand nombre de comptes. De plus, il prend naturellement en compte les **poids des arêtes**, ce qui est essentiel ici puisque les interactions entre comptes sont quantifiées par une mesure de similarité temporelle.

Un autre avantage majeur réside dans son caractère **hiérarchique et non supervisé** : l'algorithme construit des communautés à différentes échelles sans nécessiter de paramétrage préalable du nombre de groupes. Cela permet de révéler des structures latentes potentiellement complexes dans les comportements de diffusion.

Enfin, l'utilisation de Louvain dans ce cadre présente une certaine originalité : il est appliqué non pas sur un réseau social explicite (abonnements, interactions), mais sur un **réseau construit à partir de similarités temporelles statistiquement évaluées**, ce qui permet d'identifier des communautés fonctionnelles de diffusion plutôt que des communautés structurelles classiques.

Cette détection est réalisée à deux niveaux :

- sur le **réseau brut**, afin d'explorer la structure globale des interactions et identifier des regroupements larges de comptes ;
- sur le **sous-réseau significatif**, afin de mettre en évidence des communautés reposant uniquement sur des relations statistiquement validées.

Dans la pratique, lorsque le sous-réseau significatif est très peu dense (faible nombre de nœuds ou d'arêtes), l'application de Louvain peut devenir peu informative. L'analyse est alors privilégiée sur le réseau brut, le sous-réseau servant principalement à valider la robustesse des relations identifiées. Néanmoins, même en présence de réseaux peu denses, cette approche est conservée dans une perspective exploratoire, afin de détecter d'éventuelles structures latentes.

On considère un graphe pondéré non orienté $G = (U, E, W)$, où U est l'ensemble des comptes, E l'ensemble des arêtes et W les poids associés. La matrice d'adjacence pondérée est définie par :

$$A_{ij} = \begin{cases} w_{ij} & \text{si une arête existe entre } i \text{ et } j \\ 0 & \text{sinon} \end{cases}$$

Le degré pondéré d'un nœud est $k_i = \sum_j A_{ij}$, et le nombre total d'arêtes est noté $m = |E|$.

L'algorithme de Louvain repose sur la maximisation de la modularité :

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j)$$

où $\delta(c_i, c_j) = 1$ si les nœuds i et j appartiennent à la même communauté. Une valeur élevée de Q indique une forte structuration du réseau en communautés, c'est-à-dire une concentration d'arêtes à l'intérieur des groupes supérieure à celle attendue dans un modèle aléatoire.

Afin de caractériser la structure du réseau, plusieurs métriques sont également considérées.

La **densité** mesure la proportion d'arêtes observées :

$$D = \frac{2|E|}{|U|(|U| - 1)}$$

Le **coefficient de clustering local** est défini par :

$$C_i = \frac{2e_i}{k_i(k_i - 1)}$$

où e_i est le nombre de triangles autour du nœud i . Le clustering moyen est donné par :

$$C = \frac{1}{|U|} \sum_{i \in U} C_i$$

Un clustering élevé indique une forte cohésion locale, caractéristique de communautés bien structurées.

L'**assortativité par degré** mesure la tendance des nœuds à se connecter à d'autres nœuds de degré similaire.

Elle est définie comme le coefficient de corrélation de Pearson entre les degrés des nœuds connectés :

$$r = \frac{\sum_{(i,j) \in E} (k_i - \bar{k})(k_j - \bar{k})}{\sum_{(i,j) \in E} (k_i - \bar{k})^2}$$

où $\bar{k}$ est le degré moyen du réseau.

Ces métriques permettent d'analyser la structure globale du réseau et d'interpréter les communautés détectées, en distinguant notamment des structures fortement connectées, hiérarchisées ou encore homogènes en termes de connectivité.

2.6 OUTILS ET NORMES DE PRÉSENTATION

Les analyses seront réalisées à l'aide des outils suivants :

- **R** ([R Core Team 2024](#)) et **R Markdown** ([Xie, Dervieux, and Riederer 2020](#)) pour la rédaction du rapport et la production de certaines visualisations ;
- **Python** (notamment **scikit-learn** pour certaines méthodes de clustering, **hdbscan** pour l'algorithme HDBSCAN, **umap-learn** pour la réduction de dimension avec UMAP, **scikit-optimize** pour l'optimisation bayésienne, **pandas** pour la manipulation des données tabulaires, **matplotlib** et **seaborn** pour les visualisations, **numpy** pour le calcul numérique et les permutations, **torch** pour la génération des embeddings par batch avec CLIP, ainsi que **NetworkX** et **igraph** pour la construction des réseaux et l'export au format *GraphML* en vue d'une utilisation dans Gephi) pour l'analyse des données ;
- **Gephi Lite** pour la visualisation et l'exploration des graphes de réseaux ([Lien](#)).

Les seuils de significativité de 5 % et 10 % seront utilisés. Les résultats seront présentés avec un arrondi à deux décimales pour les tableaux, graphiques et p-values. Toutefois, lorsque cela est nécessaire pour garantir une précision suffisante, un arrondi pouvant aller jusqu'à cinq décimales pourra être appliqué à l'ensemble des résultats.

3 RÉSULTATS : DYNAMIQUES DE DIFFUSION DU RÉCIT “C’EST NICOLAS QUI PAIE”

Cette section présente les principaux résultats de l’analyse de la diffusion d’images sur la plateforme X. L’objectif est de caractériser les mécanismes de propagation du récit étudié, en distinguant les dynamiques organiques des comportements potentiellement coordonnés.

L’analyse s’appuie sur trois niveaux complémentaires :

- une description globale du corpus (images, comptes, temporalité) ;
- une étude des interactions entre comptes ;
- une analyse des réseaux de diffusion, intégrant la dimension temporelle et une validation statistique.

Cette approche progressive permet de passer d’une vision descriptive des données à l’identification de structures de coordination au sein du réseau.

3.1 STRUCTURATION ET DYNAMIQUES DES CORPUS D’IMAGES ET DE TWEETS : CLUSTERING, ENGAGEMENT ET THÉMATIQUES

— Analyse des dynamiques d’engagement et de diffusion des clusters d’images

Dans notre échantillon, **217 580 tweets** publiés par **43 779 comptes uniques** contiennent **26 148 images**, dont **5 731 dupliquées**, révélant une réutilisation fréquente de certains visuels sur la plateforme.

Après extraction des représentations visuelles via CLIP, réduction de dimension avec UMAP et clustering par HDBSCAN, **105 clusters d’images** ont été identifiés. La taille de ces clusters est fortement hétérogène (de 23 à 4 661 images, moyenne : 193), suggérant des **dynamiques de diffusion contrastées**. Certains clusters correspondent à des images massivement réutilisées, indiquant une forte viralité, tandis que d’autres regroupent des contenus plus diversifiés ou faiblement diffusés.

Le diagramme à barres dans la figure 8 ci-après présente le top 10 des clusters avec le plus d’engagement selon nos données. L’indicateur d’engagement est construit à partir de quatre variables (**engagement, partages, vues et nombres d’interactions au sein du cluster**), préalablement standardisées pour neutraliser les effets d’échelle. Un score pondéré⁶ est ensuite calculé, avec un poids plus faible attribué aux vues, car elles reflètent moins l’engagement réel que les interactions et les partages.

L’analyse temporelle met en évidence plusieurs **pics d’activité**, notamment entre mi-juin et mi-juillet (cf graphique à droite de la figure 8 ci-avant). Durant ces périodes, les comptes impliqués génèrent en moyenne environ **12 179 vues par publication** (cf. figure 8 ci avant). Ces observations suggèrent l’existence de phases

6.

$\text{Score}_{\text{cluster}} = 0,3 \times \text{engagement} + 0,3 \times \text{partages} + 0,3 \times \text{nombre d'interactions du cluster} + 0,1 \times \text{vues}$




FIGURE 8 – Quelques métriques globales concernant les publications

d’intensification de la diffusion du récit étudié. Afin d’explorer cette hypothèse, nous examinons dans la section suivante les **interactions entre comptes**.

Dans la figure 8 ci avant, sur le graphique à droite, les clusters les plus engageants sont dominés par quelques groupes, notamment le cluster 83. Ce dernier regroupe des contenus politiques variés et génère des niveaux d’interaction très élevés. A l’inverse, certains clusters plus spécifiques, comme le cluster 01 centré sur une thématique précise (“contrat social”, “Nicolas qui paie”), présentent également un niveau d’engagement notable, tandis que les clusters issus du reclustering avec bruit (indices ≥ 76) traduisent des dynamiques de diffusion plus diffuses mais néanmoins actives.

— Typologie thématique des clusters d’images identifiés par HDBSCAN

TABEAU 2 – Regroupement thématique des clusters d’images identifiés par l’algorithme HDBSCAN

Topics	Description
Narratifs politiques et discours idéologiques	Images diffusant des messages ou revendications politiques (immigration, politiques publiques, conflits, slogans). Elles participent aux cadrages politiques en ligne. Nombre de clusters concernés : 15, dont les clusters 1 et 79.
Acteurs politiques, institutions et médias	Images de personnalités, institutions ou médias (plateaux TV, logos, responsables). Elles commentent l’actualité et incarnent les débats. Nombre de clusters concernés : 13.

Topics	Description
Memes, humour et détournements visuels	Images humoristiques ou virales (memes, détournements, références culturelles, IA). Elles simplifient et diffusent des messages politiques. Nombre de clusters concernés : 16, dont le cluster 62.
Captures d'écran et circulation de contenus numériques	Captures d'écran (tweets, articles, messages, graphiques). Elles reflètent la circulation et le partage d'informations (véridiques ou non) en ligne. Nombre de clusters concernés : 21
Représentations visuelles du quotidien et symboles sociaux	Images représentant des objets, lieux, situations du quotidien ou symboles culturels (produits de consommation, paysages urbains, transports, foules, etc.), mobilisés pour illustrer ou contextualiser certains messages politiques. Nombre de clusters concernés : 41.

Le tableau 2 présente un regroupement thématique des clusters d'images identifiés par l'algorithme HDBSCAN. Il met en évidence cinq grands topics correspondant aux principaux types de contenus visuels observés, notamment des mèmes politiques autour de la figure de "Nicolas qui paie", utilisée pour symboliser le contribuable français censé financer différentes dépenses publiques, ainsi que d'autres catégories d'images liées aux acteurs politiques, aux symboles ou à des objets du quotidien. Nos clusters analysés dans la suite du rapport sont le cluster 1 qui appartient au premier topic du tableau 2, le cluster 62 qui lui appartient au troisième topic et le cluster 79 au quatrième topic mais traite de l'immigration.

Dans la figure 9, on présente plusieurs exemples de regroupements obtenus avec HDBSCAN. Ces résultats montrent que l'algorithme parvient non seulement à capturer la similarité visuelle entre les images, mais également leur proximité sémantique. Le cluster 62 illustre ainsi un cas où les images, bien que visuellement différentes, relèvent de thématiques proches. Le cluster 79 rassemble quant à lui des contenus portant sur l'immigration, malgré des représentations variées (graphiques, textes, panneau de signalisation etc.). À l'inverse, le cluster 1 met en évidence une forte cohérence visuelle, notamment avec la présence récurrente du personnage Nicolas, tout en conservant une cohérence thématique autour du contrat social. On observe également que la Caisse d'Allocations Familiales (CAF) apparaît dans ce cluster : même si elle ne partage pas de similarité visuelle évidente avec les autres images, son intégration reste cohérente sur le plan sémantique. L'ensemble de ces observations confirme que notre pipeline de traitement et de regroupement d'images (CLIP + UMAP + HDBSCAN + optimisation bayésienne) capture simultanément la structure visuelle et la structure conceptuelle des images, ce qui renforce la pertinence de son utilisation dans notre étude.

Concernant les doublons détectés avec le *perceptual hashing*, les résultats sont présentés en annexe, à la section A.4.



FIGURE 9 – Illustration de quelques clusters issus de l'algorithme HDBSCAN, mettant en évidence la capture conjointe des caractéristiques visuelles et sémantiques des images

3.2 STRUCTURE DES INTERACTIONS ENTRE COMPTES UTILISATEURS

L'étude des interactions repose sur la variable *join_post_post_type*, qui distingue trois types de publications : *original*, *comment* et *quote*.

L'analyse se concentre sur les publications de type **comment** et **quote**, car elles impliquent des interactions explicites entre comptes et permettent d'observer les mécanismes de diffusion et de réaction au contenu.

Cette approche permet d'identifier les comptes qui structurent l'engagement, ainsi que les relations d'amplification entre utilisateurs.

3.2.1 Comptes centraux dans la génération d'interactions

La figure 10 met en évidence une forte concentration de l'attention autour d'un nombre limité de comptes. Le compte *nicolasquipaie* apparaît comme le principal pôle d'attraction, avec **39 822** interactions (commentaires et citations). Il domine nettement les autres comptes, qui génèrent des volumes d'engagement significatifs mais bien inférieurs.

Au-delà de cette attractivité, ce compte se distingue également par son niveau d'activité élevé, suggérant un double rôle :

- producteur de contenu (publication initiale),
- point focal des interactions (réactions des autres comptes).

Cette configuration est caractéristique de ce que l'on peut interpréter comme un nœud central de diffusion, autour duquel s'organise une large part de l'engagement observé.




FIGURE 10 – Analyse des interactions entre les comptes

3.2.2 Comptes les plus réactifs aux publications principales

Afin de mieux comprendre qui amplifie effectivement le contenu, nous examinons les comptes qui réagissent le plus fréquemment aux publications des comptes centraux.

Deux horizons temporels sont considérés :

- une fenêtre de **7 jours**, capturant les réactions rapides ;
- une fenêtre de **1 mois**, permettant d'observer des dynamiques plus étalées.

Dans la fenêtre courte, les interactions varient entre 19 et 28 réactions par paire de comptes. Les comptes **grok** (IA de X) et **nicolasquipaie** apparaissent comme les principales sources de publications suscitant des réactions.

Du côté des comptes récepteurs, certains profils reviennent de manière récurrente, notamment **euriskosansinfo**, **boulisquen** et **b80420**.

Lorsque l'on élargit l'échelle temporelle à un mois, la structure se stabilise et **nicolasquipaie** apparaît encore plus clairement comme le principal émetteur. Plusieurs comptes, tels que **boulisquen**, **jenjisuza** et **b80420**, se distinguent par leur présence répétée, suggérant un rôle d'amplificateurs réguliers.

TABLEAU 3 – Réactions sur 7 jours et sur 1 mois

(a) Réactions sur 7 jours				(b) Réactions sur 1 Mois			
Source	Récepteur	Interactions	Date début	Source	Récepteur	Interactions	Date début
grok	euriskosansinfo	28	2025-07-24	nicolasquipaie	boulisquen	63	2025-01-12
nicolasquipaie	boulisquen	24	2025-01-23	nicolasquipaie	captaingusss	57	2025-01-12
grok	crxbtc	23	2025-07-10	nicolasquipaie	b80420	53	2025-02-11
nicolasquipaie	b80420	23	2025-09-04	nicolasquipaie	jenjisuza	50	2025-05-12
nicolasquipaie	b80420	22	2025-02-06	nicolasquipaie	boulisquen	45	2025-02-11
nicolasquipaie	dsoulaine	21	2025-09-04	nicolasquipaie	jenjisuza	39	2025-03-13
grok	kelediabate	20	2025-07-10	nicolasquipaie	b80420	38	2025-08-10
nicolasquipaie	boulisquen	20	2025-02-20	nicolasquipaie	philjensen63644	38	2025-06-11
nicolasquipaie	jcetmf	19	2025-01-16	nicolasquipaie	jenjisuza	38	2025-02-11
nicolasquipaie	captaingusss	19	2025-01-23	nicolasquipaie	astobenfit	36	2025-02-11
nicolasquipaie	boulisquen	19	2025-01-30	grok	euriskosansinfo	36	2025-07-11
nicolasquipaie	b80420	19	2025-08-28		onapalechoix	35	2025-08-10
	onapalechoix	19	2025-08-21	nicolasquipaie	lily_bertine	34	2025-05-12
nicolasquipaie	captaingusss	18	2025-01-30	nicolasquipaie	jenjisuza	34	2025-06-11
grok	crazyjo63888181	17	2025-07-10	nicolasquipaie	jenjisuza	34	2025-01-12

3.2.3 Dynamique temporelle des réactions aux publications de “nicolasquipaie”

Ces premiers résultats mettent en évidence une structure hiérarchisée des interactions. Cependant, ils ne permettent pas encore de déterminer si ces comportements relèvent de réactions spontanées ou de dynamiques plus organisées.

Pour approfondir cette question, nous analysons la dimension temporelle des interactions dans un premier temps, sans tenir compte des images, en nous concentrant sur les publications les plus visibles.

Un indicateur d'attractivité est construit à partir de plusieurs métriques (**engagement**, **vues**, **partages**), puis standardisé afin d'identifier les contenus les plus performants. Nous retenons ainsi les 70 % de publications les plus attractives.

L'analyse temporelle (cf. figure 11 ci-après) révèle que certains comptes, notamment **philjensen63644**, **boulisquen**, **jenjisuza** et **b80420**, présentent une proximité temporelle récurrente avec les publications de nicolasquipaie.

Autrement dit, ces comptes interviennent de manière rapide et répétée après la publication des contenus, ce qui suggère un rôle actif dans leur diffusion.

On observe également que les publications de nicolasquipaie sont réparties sur l'ensemble de la période étudiée, avec des phases d'intensification marquées. Ces phases correspondent à des moments où les réactions se concentrent dans le temps, renforçant la visibilité du contenu




FIGURE 11 – Réactions des comptes au post source de nicolasquipaie

Toutefois, l'analyse descriptive ne permet pas de déterminer si ces comportements relèvent d'une diffusion organique ou d'une coordination structurée. Pour explorer cette question, nous analysons la **structure des réseaux de diffusion des images**.

3.3 ANALYSE DES RÉSEAUX DE DIFFUSION DES IMAGES

L'analyse des interactions entre comptes a mis en évidence l'existence de comptes centraux, de comportements récurrents de réaction et de proximités temporelles suggérant des mécanismes d'amplification.

Pour approfondir ces résultats, nous changeons maintenant d'échelle d'analyse en nous concentrant non plus uniquement sur les interactions entre comptes, mais sur les **contenus eux-mêmes**, en particulier les images diffusées.

L'application de l'algorithme HDBSCAN sur les embeddings d'images a permis d'identifier **105 clusters distincts**, correspondant à des groupes d'images visuellement similaires et susceptibles de porter des messages communs.

L'objectif est alors de comprendre comment ces contenus circulent entre les comptes, et si leur diffusion repose sur des comportements spontanés ou sur des formes de coordination plus structurées.

Dans cette perspective, nous débutons par une analyse de la sensibilité du paramètre de décroissance temporelle λ , qui intervient dans la fonction de pondération utilisée dans la statistique de coordination. Nous nous concentrons ensuite sur les clusters **01, 62 et 79**, qui présentent à la fois une cohérence thématique avec le récit étudié et une activité de diffusion notable.

3.3.1 Diffusion coordonnée d'images dans le cluster d'image 01

— Description des réseaux en fonction du paramètre de décroissance temporelle λ

Le **cluster 01** regroupe **443 images** (cf. tableau 2), majoritairement centrées sur l'usage perçu des ressources publiques et associées à des représentations souvent polarisantes. Le personnage de « *Nicolas qui paie* » y occupe une place centrale, servant de support visuel au discours sur la redistribution.

L'analyse du réseau de diffusion associé révèle une structure particulièrement dense, avec **107 comptes reliés par 2 789 liens**. Ce niveau de connectivité suggère l'existence de **dynamiques collectives non triviales** (cf. figure 12 ci-dessous).




FIGURE 12 – Graphe de réseau des comptes ayant publié les images du cluster 1 (HDBSCAN), pondéré par la proximité temporelle et l'intensité des interactions entre les comptes reposteurs ($\lambda = 0,3$)

Cette première lecture est renforcée par l'analyse de la structure communautaire : la **modularité** augmente avec le paramètre λ , passant de $Q = 0,17$ à $Q = 0,42$. Plus la contrainte temporelle est forte, plus le réseau se structure en **communautés distinctes**, ce qui s'éloigne d'une diffusion aléatoire.

L'algorithme de Louvain met en évidence plusieurs groupes denses. Le compte **nicolasquipaie** apparaît comme un **hub**⁷ central, connecté à de nombreux utilisateurs (*merlin_thanael*, *boulisquen*, *roge_jules*). D'autres pôles émergent autour de **kryptomangane** et **cdgideedefrance**, ainsi que des sous-groupes très actifs (*canamago*, *divasonic_xx*).

Au-delà de cette structuration en communautés, on observe également des **connexions fortes entre plusieurs hubs de communautés différentes**. Des comptes tels que **nicolasquipaie**, **cdgideedefrance**, **kryptomangane**, **canamago** et **roge_jules** sont reliés par des arêtes particulièrement épaisses, indiquant une **forte proximité temporelle des publications** (ici pour $\lambda = 0,3$) ainsi qu'une **intensité élevée des interactions**.

Cette configuration suggère l'existence d'un **niveau de coordination inter-communautés**, où certains

7. Un hub est un nœud central dans un réseau, fortement connecté à de nombreux autres nœuds, et qui joue un rôle clé dans la diffusion ou la propagation de l'information.

comptes centraux ne se contentent pas d'animer leur propre groupe, mais participent également à la circulation rapide du contenu entre différentes communautés.

Cette structuration suggère des comportements organisés, mais ne suffit pas à conclure à une coordination effective. Pour tester cette hypothèse, nous appliquons un **test de permutation** permettant d'évaluer la significativité des proximités temporelles observées.

— Analyse de la sensibilité au paramètre λ

Pour chaque valeur de λ , un **test de permutation avec $B = 2\,000$ permutations** a été appliqué pour identifier les liens de coordination significatifs. Les résultats sont visualisés par des **Manhattan plots** (cf. figure 13 ci-après) où les lignes horizontales en pointillé représentent le seuil de significativité $\alpha = 10\%$ et donc $-\log_{10}(\alpha) = 1$.




FIGURE 13 – Distribution des p-values ajustées en fonction du paramètre λ - Cluster 01

Le **nombre de liens significatifs diminue lorsque λ augmente**, ce qui reflète le rôle de la contrainte temporelle : seules les interactions très rapprochées restent détectées comme coordonnées.

Certaines relations persistent néanmoins pour toutes les valeurs de λ , notamment entre *canamago*, *divasonic_xx*, *extreme_dr watt*, *pampamplemousse* et *cdgideedefrance*, ainsi qu'entre *haroldpainfinch* et *henri_bruneau*. Ces liens robustes suggèrent l'existence de **noyaux fortement synchronisés**.

Par ailleurs, compte tenu du contrôle du taux de fausses découvertes (FDR) fixé à 10 %, on s'attend à ce qu'environ 10 % des liens identifiés comme significatifs soient en réalité des faux positifs. Par exemple, pour 14 liens significatifs, environ 1 à 2 liens pourraient ne pas correspondre à une véritable coordination.

Ce résultat est visible dans la figure 14 ci après (NB : les couleurs n'ont pas de signification statistique ni communautaire selon l'algorithme de Louvain ; elles servent uniquement à visualiser de petits groupes qui peuvent varier avec la valeur de λ . Les nœuds les plus influents restent toujours présents, seule leur couleur peut changer).




FIGURE 14 – Persistance des comptes significativement coordonnés en fonction du paramètres de décroissance temporelle

Un résultat marquant émerge : le compte **nicolasquipaie**, pourtant central, ne présente aucune coordination statistiquement significative quel que soit le paramètre de décroissance λ considéré.

Ce contraste entre **centralité structurelle** et **absence de coordination détectée** suggère une dissociation entre production de contenu et amplification coordonnée.

Ces résultats indiquent un mécanisme de diffusion en deux niveaux :

- un **rôle d'initiation** assuré par des comptes centraux ;
- une **amplification coordonnée** portée par des groupes plus restreints.

Ce schéma est cohérent avec l'analyse temporelle (cf. figure 11 ci-avant), où certains comptes publient de manière rapprochée autour des contenus les plus attractifs.

Ainsi, la viralité observée repose sur une combinaison de **visibilité centrale** et de **coordination locale**, caractéristique de dynamiques de diffusion structurées.

L'ensemble de ces observations met en évidence un schéma de diffusion multi-niveaux, combinant des hubs centraux pour initier le contenu et des groupes d'amplificateurs coordonnés pour maximiser sa propagation.

3.3.2 Structure du réseau des comptes dans le cluster 62

Ce cluster regroupe **135 images** (voir tableau 2), principalement des mèmes, dont une part importante est associée au récit “*Nicolas qui paie*”. Contrairement au cluster 01, qui présentait des signaux clairs de coordination locale, le cluster 62 permet d'examiner une situation intermédiaire entre diffusion structurée et dynamique organique.

Le réseau associé comprend **45 comptes** pour **231 interactions**, avec une densité de **0,23**, indiquant un niveau de connectivité modéré. Comme observé précédemment dans l'analyse globale des interactions, la diffusion repose ici aussi sur un **noyau restreint de comptes actifs**, entouré d'utilisateurs plus périphériques.

La **modularité élevée** (de **0,28 à 0,61** lorsque λ augmente) confirme que, comme dans le cluster 01, les interactions tendent à se structurer en **communautés distinctes lorsque l'on renforce la contrainte temporelle**. Ce résultat est cohérent avec les observations précédentes : la diffusion des contenus ne se fait pas de manière homogène, mais via des groupes d'utilisateurs relativement cohésifs.

Par ailleurs, le **coefficient de clustering très élevé** ($\approx 0,97$) et l'**assortativité positive** ($\approx 0,56$) indiquent que les comptes les plus actifs interagissent préférentiellement entre eux, formant des **groupes locaux très denses**. Ce type de configuration avait déjà été suggéré dans l'analyse des interactions, où certains comptes apparaissaient comme des amplificateurs réguliers.

On retrouve d'ailleurs plusieurs comptes déjà identifiés comme centraux dans les sections précédentes, notamment **nicolasquipaie**, **rouge_jules** ou encore **stephdulux**, ce qui confirme la **stabilité des rôles dans le réseau**, indépendamment du contenu spécifique diffusé.

Cependant, **aucune interaction n'est statistiquement significative** au sens du test de permutation. Ce résultat marque une différence importante avec le cluster 01 : malgré une structuration apparente du réseau et une activité non négligeable, **les proximités temporelles observées restent compatibles avec une diffusion non coordonnée** (cf figure 18 à la section A.3.1 en annexe).

Ainsi, ce cluster illustre un cas où la diffusion est **structurée socialement** (communautés, noyau actif) mais **sans preuve de coordination temporelle intentionnelle**.

Ce résultat suggère que certains contenus, en particulier les mèmes peuvent circuler efficacement via des **dynamiques d'appropriation collective**, sans nécessiter de synchronisation explicite entre les comptes.




FIGURE 15 – Réseau des comptes qui publient les images du cluster 62 (HDBSCAN)

3.3.3 Organisation communautaire de la diffusion dans le cluster 79

Le cluster 79 regroupe **56 images**, principalement centrées sur des thématiques liées à l'immigration. Contrairement aux clusters précédents, il correspond à un contenu plus spécifique, mais diffusé à une échelle plus restreinte.

Le réseau associé comprend **17 comptes**, avec une densité de **0,18**, ce qui en fait le réseau le **moins connecté** parmi les clusters étudiés. Cette faible densité contraste avec les structures observées dans les clusters 01 et 62, et suggère une diffusion plus fragmentée.

Néanmoins, la **modularité élevée** ($\approx 0,55$ à $0,67$) indique, là encore, une organisation en **communautés distinctes**, confirmant une propriété déjà observée à plusieurs niveaux de l'analyse : la diffusion des contenus s'opère rarement de manière aléatoire, même lorsque le réseau est peu dense.

Contrairement au cluster 01, aucun **hub dominant clair** n'émerge, bien que **nicolasquipaie** conserve une certaine centralité relative. Cette observation est cohérente avec les résultats précédents : ce compte joue un rôle structurant global, mais son influence peut varier selon les types de contenus.

Certaines interactions apparaissent **répétées et persistantes**, notamment entre **cdgideedefrance** et **robert-surcouf9**, ou entre **cocombr3masqu3** et **gregoir89186966**. Toutefois, comme dans le cluster 62, ces relations ne sont **pas statistiquement significatives**.

Ce résultat est particulièrement intéressant lorsqu'on le compare aux analyses précédentes : des **proximités temporelles existent**, des **relations récurrentes sont observées**, mais elles restent **insuffisantes pour conclure à une coordination structurée**.

Ainsi, le cluster 79 illustre une configuration différente une diffusion **fragmentée**, portée par **petits groupes faiblement connectés** mais sans coordination détectable (cf figure 19 à la section A.3.2 en annexe).




FIGURE 16 – Réseau des comptes qui publient les images du cluster 79 (HDBSCAN) en fonction du paramètre λ de décroissance temporelle

4 DISCUSSIONS

4.1 SYNTHÈSE DE L'ÉTUDE

L'étude de la diffusion du récit « *C'est Nicolas qui paie* » sur la plateforme X permet de conclure que les **objectifs fixés ont été globalement atteints**.

Le premier objectif, portant sur l'analyse de la coordination des publications à partir de la similarité visuelle et sémantique ainsi que de la proximité temporelle, est validé. Le pipeline méthodologique mis en place a permis d'identifier des structures cohérentes de diffusion. Les tests de permutation appliqués aux réseaux pondérés mettent en évidence, notamment dans le cluster 01, des **liens de coordination statistiquement significatifs** entre certains comptes, robustes aux variations du paramètre de décroissance temporelle.

Le second objectif, relatif à l'identification d'une amplification artificielle, est également atteint. Plusieurs indicateurs convergent : des **pics d'activité concentrés dans le temps**, un **niveau d'engagement élevé** sur certains clusters d'images, ainsi que des **réactions rapides et répétées** de groupes de comptes. Ces éléments suggèrent que certains contenus ont bénéficié d'une amplification dépassant une diffusion strictement organique.

Le troisième objectif, visant à détecter des **opérations de diffusion structurées**, est partiellement vérifié. L'analyse des réseaux, notamment à travers la détection de communautés (algorithme de Louvain), met en évidence des **groupes d'utilisateurs fortement connectés**, organisés autour de noyaux actifs. Dans plusieurs clusters (01, 62 et 79), ces communautés présentent des interactions internes denses, indiquant des dynamiques collectives structurées.

Par ailleurs, les analyses révèlent une **réutilisation importante des contenus**, avec plus de 5 700 images dupliquées. Certains clusters présentent une activité de diffusion particulièrement intense, traduisant des mécanismes de propagation répétitifs difficilement compatibles avec une simple diffusion spontanée.

Cependant, la coordination n'est pas homogène selon les clusters. Si des relations significatives sont observées dans certains cas (cluster 01), d'autres (clusters 62 et 79) présentent des structures organisées mais sans coordination statistiquement démontrée, suggérant des dynamiques davantage organiques.

Dans l'ensemble, les résultats mettent en évidence des **schémas de diffusion non aléatoires**, reposant sur une combinaison de réutilisation de contenus, de structuration communautaire et, dans certains cas, de coordination temporelle.

Quant aux hypothèses de recherche, elles sont globalement confirmées, avec des nuances.

D'abord, l'hypothèse 1, relative à l'existence de schémas temporels non aléatoires révélant des comportements coordonnés, est **partiellement vérifiée**. Des proximités temporelles significatives sont observées dans

certaines clusters, notamment le cluster 01, mais ces phénomènes ne sont pas généralisés à l'ensemble des données.

L'hypothèse 2, portant sur l'existence d'une amplification artificielle de certaines images, est **globalement vérifiée**. La forte présence de doublons, les niveaux élevés d'engagement et les réactions rapides de certains comptes suggèrent des mécanismes de diffusion dépassant une dynamique organique, sans toutefois permettre d'établir une intentionnalité de manière certaine.

Enfin, l'hypothèse 3 est **validée**. L'analyse met en évidence une structuration en communautés distinctes, caractérisées par des dynamiques de diffusion différenciées selon les clusters étudiés.

4.2 VALIDITÉ ET APPORTS DE L'APPROCHE

L'un des principaux apports de ce travail réside dans la reconstitution d'un réseau de diffusion à partir de similarités temporelles statistiquement validées. Contrairement aux approches classiques fondées sur des réseaux observés (interactions, abonnements), les liens entre comptes sont ici **inférés** à partir des données. Cette approche permet d'identifier des formes de coordination implicite, en combinant apprentissage automatique (CLIP, UMAP, HDBSCAN), inférence statistique (tests de permutation) et analyse de graphes. Elle offre ainsi une vision intégrée des mécanismes de diffusion.

La robustesse des résultats repose sur la richesse des données et sur l'utilisation de méthodes non paramétriques. Le contrôle du taux de fausses découvertes via la procédure de Benjamini-Hochberg garantit que la proportion de liens identifiés à tort reste maîtrisée, malgré des dépendances plausiblement positives entre tests.

4.3 FORCES DE LA MÉTHODOLOGIE

L'approche proposée repose sur un **pipeline multi-modal intégré**⁸, combinant contenu visuel, structure du réseau et temporalité.

L'utilisation de CLIP permet de capturer la dimension sémantique des images, au-delà de la similarité visuelle (Radford et al. 2021). La réduction de dimension par UMAP préserve la structure globale des données (Sainburg, McInnes, and Gentner 2021 ; McInnes, Healy, and Melville 2018), tandis que HDBSCAN permet d'identifier des clusters dans des données bruitées sans fixer le nombre de groupes (Malzer and Baum 2020).

L'optimisation bayésienne facilite la sélection des hyperparamètres tout en limitant le coût computationnel (Wu et al. 2019). La prise en compte de la dimension temporelle, via une fonction de pondération et une

8. Le pipeline combine le perceptual hashing pour la détection des doublons, les embeddings visuels avec CLIP, la réduction de dimension via UMAP, le clustering avec HDBSCAN, ainsi que la construction de réseaux temporels et des tests de permutation pour l'inférence des liens de coordination.

analyse de sensibilité au paramètre λ , renforce la robustesse des résultats un peu dans l'esprit de Nizzoli et al. (2021).

L'algorithme de Louvain permet d'identifier efficacement des communautés structurées, avec de bonnes performances en termes de cohésion et de passage à l'échelle (Srinivas and Velusamy 2025).

Enfin, le contrôle de la FDR permet de passer d'une analyse exploratoire à une **inférence statistique rigoureuse**. Contrairement aux approches classiques (Wohlert et al. 2025), cette méthode multi-modale permet de détecter à la fois les hubs et les groupes coordonnés.

4.4 LIMITES

Plusieurs limites doivent être prises en compte dans cette étude.

La **séparabilité des embeddings CLIP** reste imparfaite, entraînant des chevauchements entre clusters (faible stabilité moyenne, cf. tableau 4). Le clustering présente également un niveau de bruit non négligeable (cf. tableau 4), et le reclustering du bruit peut produire des groupes peu pertinents.

Les méthodes UMAP et HDBSCAN sont sensibles aux hyperparamètres, rendant les résultats dépendants des choix effectués.

Les données issues de l'Application Programming Interface (interface de programmation d'application) (API) X peuvent être incomplètes, ce qui peut biaiser la structure du réseau.

Enfin, une forte cohésion communautaire ou des proximités temporelles ne constituent pas en soi une preuve de coordination intentionnelle.

4.5 PERSPECTIVES

Plusieurs pistes d'amélioration peuvent être envisagées pour approfondir cette étude.

Un premier axe concerne l'amélioration du clustering du bruit, qui pourrait bénéficier d'approches hybrides combinant HDBSCAN et des méthodes hiérarchiques (Malzer and Baum 2020). Cette étape permettrait d'obtenir des regroupements plus précis et de mieux distinguer les signaux pertinents des anomalies.

Parallèlement, une analyse temporelle plus fine offrirait une compréhension approfondie des comportements de coordination, en révélant par exemple des patterns d'activité spécifiques à certaines périodes.

L'intégration de données textuelles constitue un autre enrichissement possible, permettant d'interpréter plus finement le contenu diffusé et d'identifier les thématiques dominantes au sein des groupes identifiés.

Enfin, l'application de cette méthodologie à d'autres récits viraux pourrait mettre en lumière des motifs de diffusion récurrents, confirmant ou nuancant les tendances observées et renforçant la généralisation des résultats.

5 CONCLUSION GÉNÉRALE

5.1 RÉSULTAT PRINCIPAL DE L'ÉTUDE

Notre étude visait à détecter la diffusion inauthentique d'images sur les réseaux sociaux, en se basant sur un dataset de tweets associées à l'expression « C'est Nicolas qui paie » sur le réseau social X. Les résultats que nous avons obtenus mettent ainsi en évidence des dynamiques de diffusion hétérogènes. Même si certaines semblent organiques, d'autres tendent à montrer statistiquement un caractère inauthentique et coordonné. Les images qui sont amplifiées par ces mécanismes présentent notamment des particularités en termes de similarité visuelle et sémantique, de répétition et de synchronisation temporelle. L'approche méthodologique que nous avons mise en œuvre, combinant vectorisation des images via CLIP, réduction de dimension avec UMAP, clustering avec HDBSCAN et construction de réseaux d'interactions entre comptes, nous a permis d'identifier des regroupements cohérents de contenus et d'analyser leur circulation dans le temps et entre comptes. Les objectifs fixés sont ainsi globalement atteints : nous sommes en mesure de détecter des schémas de coordination, d'identifier des amplifications artificielles et de caractériser des structures de diffusion associées à des comportements inauthentiques.

5.2 UTILISATIONS ET APPLICATIONS PRATIQUES

Notre approche fournit un cadre méthodologique robuste pour l'étude de la diffusion coordonnée de contenus visuels. Plus largement, l'articulation entre similarités visuelle et sémantique, dynamiques temporelles et analyse de réseaux constitue une approche transférable à d'autres contextes d'étude. Dans ce cadre, des modules opérationnels ont été développés (vectorisation, clustering, construction de réseaux) et peuvent être réutilisés ou adaptés à d'autres jeux de données. Elle peut contribuer à la détection de campagnes organisées, à l'analyse de comportements inauthentiques, à la compréhension des dynamiques de communautés et au renforcement des outils de modération et de recherche en désinformation. Les modules développés peuvent donc être réutilisés dans d'autres contextes d'analyse.

5.3 RECOMMANDATIONS

Nos résultats doivent néanmoins être interprétés avec prudence. Il s'agit d'une analyse réalisée sur un dataset spécifique, et nous avons conscience que les dynamiques observées peuvent dépendre fortement du sujet étudié. En particulier, les thématiques associées à « Nicolas qui paie » constituent un terrain propice à la manipulation informationnelle, ce qui peut favoriser l'émergence de comportements inauthentiques et coordonnés, qu'on peut supposer intrinsèquement liés au dataset. Par ailleurs, des améliorations pourraient être apportées à la constitution du dataset notamment. Une collecte plus large, intégrant davantage de

hashtags ou de variantes de requêtes (pas seulement ceux mentionnant explicitement le syntagme « Nicolas qui paie »), ainsi que la prise en compte de l'intégralité des chaînes de réponses aux tweets capturés, permettrait de mieux capturer les dynamiques conversationnelles. Ces extensions offriraient une vision plus complète des interactions et renforceraient la capacité à détecter et caractériser les comportements inauthentiques.

6 LISTE DES RÉFÉRENCES

- Cinelli, Matteo, Stefano Cresci, Walter Quattrociocchi, Maurizio Tesconi, and Paola Zola. 2022. “Coordinated Inauthentic Behavior and Information Spreading on Twitter.” *Decision Support Systems* 160 : 113819. <https://doi.org/https://doi.org/10.1016/j.dss.2022.113819>.
- Daily Dose of Data Science. 2023. “Bayesian Optimization for Hyperparameter Tuning.” 2023. <https://www.dailydoseofds.com/bayesian-optimization-for-hyperparameter-tuning/>.
- Le Nouvel Obs. 2025. “‘Nicolas-Qui-Paie, Le Retour de « Mon Fisc, Ma Bataille », Version Réseaux Sociaux.’” *Le Nouvel Observateur*. August 24, 2025.
- Lehigh University. n.d. “Bayesian Optimization.” n.d. https://srrweb.cc.lehigh.edu/app/bayesian_optimization.
- Malzer, Claudia, and Marcus Baum. 2020. “A Hybrid Approach to Hierarchical Density-Based Cluster Selection.” In *2020 IEEE International Conference on Multisensor Fusion and Integration for Intelligent Systems (MFI)*, 223–28. IEEE. <https://doi.org/10.1109/mf49285.2020.9235263>.
- McInnes, Leland, John Healy, and James Melville. 2018. “UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction.” *arXiv Preprint arXiv :1802.03426*. <https://doi.org/10.48550/arXiv.1802.03426>.
- Murero, Monica. 2023. “Coordinated Inauthentic Behavior : An Innovative Manipulation Tactic to Amplify COVID-19 Anti-Vaccine Communication Outreach via Social Media.” *Frontiers in Sociology* Volume 8 - 2023. <https://doi.org/10.3389/fsoc.2023.1141416>.
- Nizzoli, Leonardo, Serena Tardelli, Marco Avvenuti, Stefano Cresci, and Maurizio Tesconi. 2021. “Coordinated Behavior on Social Media in 2019 UK General Election.” *Proceedings of the International AAAI Conference on Web and Social Media* 15 (1) : 443–54. <https://doi.org/10.1609/icwsm.v15i1.18074>.
- R Core Team. 2024. *R : A Language and Environment for Statistical Computing*. Vienna, Austria : R Foundation for Statistical Computing. <https://www.R-project.org/>.
- Radford, Alec, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, et al. 2021. “Learning Transferable Visual Models from Natural Language Supervision.” *arXiv Preprint arXiv :2103.00020*. <https://doi.org/10.48550/arXiv.2103.00020>.
- Ruffo, Giancarlo, Alfonso Semeraro, Anastasia Giachanou, and Paolo Rosso. 2023. “Studying Fake News Spreading, Polarisation Dynamics, and Manipulation by Bots : A Tale of Networks and Language.” *Computer Science Review* 47 : 100531. <https://doi.org/https://doi.org/10.1016/j.cosrev.2022.100531>.
- Sainburg, Tim, Leland McInnes, and Timothy Q. Gentner. 2021. “Parametric UMAP Embeddings for Representation and Semisupervised Learning.” *Neural Computation* 33 (11) : 2881–2907. https://doi.org/10.1162/neco_a_01434.
- Samanta, Priyanka, and Shweta Jain. 2021. “Analysis of Perceptual Hashing Algorithms in Image Manipu-

- lation Detection.” *Procedia Computer Science* 185 : 203–12. <https://doi.org/https://doi.org/10.1016/j.procs.2021.05.021>.
- Shuken, Steven R., and Margaret W. McNerney. 2021. “Visualizing the Costs and Benefits of Correcting p-Values for Multiple Hypothesis Testing in Omics Data.” *bioRxiv*. <https://doi.org/10.1101/2021.09.09.459558>.
- Srinivas, Amedapu, and R. Leela Velusamy. 2025. “Computer Science and Engineering, Online Social Networks, Communities Detection.” *International Journal of Applied Mathematics* 38 (5). <https://doi.org/10.12732/ijam.v38i5.985>.
- Stella, Massimo, Emilio Ferrara, and Manlio De Domenico. 2018. “Bots Increase Exposure to Negative and Inflammatory Content in Online Social Systems.” *Proceedings of the National Academy of Sciences* 115 (49) : 12435–40. <https://doi.org/10.1073/pnas.1803470115>.
- Wohlert, Inga K., Davide Vega, Matteo Magnani, and Alexandra Segerberg. 2025. “Detecting Coordinated Behaviour on Video-First Platforms : The Challenge of Multimodality and Complex Similarity on TikTok.” *arXiv Preprint*, no. arXiv :2506.05868v2. <https://arxiv.org/pdf/2506.05868v2>.
- Wu, Jia, Xiu-Yun Chen, Hao Zhang, Li-Dong Xiong, Hang Lei, and Si-Hao Deng. 2019. “Hyperparameter Optimization for Machine Learning Models Based on Bayesian Optimizationb.” *Journal of Electronic Science and Technology* 17 (1) : 26–40. <https://doi.org/https://doi.org/10.11989/JEST.1674-862X.80904120>.
- Xie, Yihui, Christophe Dervieux, and Emily Riederer. 2020. *R Markdown Cookbook*. Boca Raton, Florida : Chapman ; Hall/CRC. <https://bookdown.org/yihui/rmarkdown-cookbook>.

A ANNEXES

A.1 PROJECTION DE CERTAINS CLUSTERS DANS LE PLAN




FIGURE 17 – Projection de 15 clusters aléatoirement dans l'espace UMAP avec les valeurs d'hyperparamètres optimaux obtenu après l'optimisation bayésienne

A.2 RÉSULTATS DE L'OPTIMISATION BAYÉSIENNE

Nous avons optimisé les paramètres de UMAP (*nombre de voisins*, *distance minimale*, *nombre de composantes*) et de HDBSCAN (*taille minimale des clusters*, *nombre de voisins*, indice DBCV). Cette étape a permis d'identifier 76 clusters, avec 7 168 images classées comme bruit (cf. tableau 4). Un reclustering ciblé de ces images a ensuite généré 29 clusters supplémentaires, réduisant le bruit à 7,22 %.

TABLEAU 4 – Hyperparamètres et scores optimaux

(a) Premier clustering		(b) Second reclustering (bruit)	
Paramètre	Valeur	Paramètre	Valeur
Nombre de voisin	8	Nombre de voisin	9
Distance minimale	0.0145	Distance minimale	0.0116
Taille minimale du cluster	43	Taille minimale du cluster	23
Nombre minimal de points à considérer	12	Nombre minimal de points à considérer	4
Nombre de Composante	14	Nombre de Composante	23
Methode de selection des clusters	eom	Methode de selection des clusters	eom
Score DBCV	0.325	Score DBCV	0.189
Taux de Bruit	0.351	Taux de Bruit	0.072
Stabilité	0.142	Stabilité	0.213
Nombre de clusters	76	Nombre de clusters	29

A.3 ANALYSE RÉSEAU

A.3.1 Manathan plot de la coordination au sein du cluster 62




FIGURE 18 – Distribution des p-values ajustées en fonction du paramètre λ - Cluster 80 (absence de liens statistiquement significatifs pour 2 000 permutations)

A.3.2 Manathan plot de la coordination au sein du cluster 79




FIGURE 19 – Distribution des p-values ajustées en fonction du paramètre λ - Cluster 80 (absence de liens statistiquement significatifs pour 2 000 permutations)

A.4 RÉSULTATS DU PERCEPTUAL HASHING POUR L'IDENTIFICATION DES DOUBLONS AVEC LE PHASH ET UN SEUIL DE 8 POUR LA DISTANCE MAXIMALE ENTRE LES EMPREINTES NUMÉRIQUES DES IMAGES



FIGURE 20 – Illustration de quelques images identifiées comme doublons par le perceptual hashing

A.5 JUSTIFICATION THÉORIQUE DU TEST DE PERMUTATION

A.5.1 Représentation des données

Les données peuvent être représentées sous forme matricielle :

$$X = \begin{pmatrix} u_1 & I_1 & t_1 \\ u_2 & I_2 & t_2 \\ u_3 & I_3 & t_3 \\ \vdots & \vdots & \vdots \\ u_i & I_j & t_N \end{pmatrix}$$

Chaque ligne correspond à une publication d'une image par un utilisateur à un instant donné.

Pour une image i , on considère l'ensemble des comptes :

$$U_i = \{u_1, \dots, u_{n_i}\}$$

et les temps associés :

$$(t_{u_1,i}, \dots, t_{u_{n_i},i})$$

A.5.2 Groupe de permutations

Pour chaque image i , on considère l'ensemble des permutations des comptes U_i :

$$\mathcal{S}_{n_i}$$

Une permutation est une bijection :

$$\pi : U_i \rightarrow U_i$$

Ce groupe agit sur les temps de publication en redistribuant les temps entre comptes.

A.5.3 Action des permutations sur les données

L'action d'une permutation π est définie par :

$$(t_{u_1,i}, \dots, t_{u_{n_i},i}) \longrightarrow (t_{\pi(u_1),i}, \dots, t_{\pi(u_{n_i}),i})$$

Ainsi, seule l'association utilisateur–temps est modifiée, **conditionnellement à chaque image**.

Après permutation, les données deviennent :

$$X^{(\pi)} = \begin{pmatrix} u_1 & I_1 & t_{\pi(1)} \\ u_2 & I_2 & t_{\pi(2)} \\ u_3 & I_3 & t_{\pi(3)} \\ \vdots & \vdots & \vdots \\ u_i & I_j & t_{\pi(N)} \end{pmatrix}$$

Cette transformation conserve :

- les images ;
- les comptes ;
- la distribution des temps de publication.

A.5.4 Hypothèse d'échangeabilité

Sous l'hypothèse nulle H_0 , les temps de publication associés à une image sont échangeables :

$$(t_{u_1,i}, \dots, t_{u_{n_i},i}) \stackrel{d}{=} (t_{\pi(u_1),i}, \dots, t_{\pi(u_{n_i}),i})$$

pour toute permutation π .

Cela signifie que la loi des données est invariante par permutation des comptes.

Cette propriété justifie l'utilisation des permutations comme modèle nul.

A.5.5 Distribution sous l'hypothèse nulle

Sous H_0 , la distribution de la statistique est donnée par :

$$\{W_{uv}^{(\pi)} : \pi \in \mathcal{S}\}$$

Cependant, le nombre de permutations étant de l'ordre de $n_i!$, le calcul exact est impossible en pratique.

A.5.6 Approximation Monte Carlo

On approxime cette distribution en générant B permutations aléatoires :

$$\pi_1, \dots, \pi_B$$

et en calculant :

$$W_{uv}^{(b)} = W_{uv}^{(\pi_b)}$$

On obtient ainsi une distribution empirique sous H_0 .

A.5.7 Convergence de la p-value

La p-value de Monte-Carlo (MC) est définie par :

$$\hat{p}_B = \frac{1 + \sum_{b=1}^B \mathbf{1}(W_{uv}^{(b)} \geq W_{uv})}{B + 1}$$

Lorsque $B \rightarrow \infty$, on a :

$$\hat{p}_B \rightarrow p$$

et

$$\sqrt{B}(\hat{p}_B - p) \xrightarrow{d} \mathcal{N}(0, p(1 - p))$$

La précision est donc de l'ordre de :

$$\mathcal{O}\left(\frac{1}{\sqrt{B}}\right)$$

A.5.8 Interprétation

Le test de permutation fournit un modèle nul non paramétrique basé uniquement sur l'hypothèse d'échangeabilité.

Une p-value faible indique que la proximité temporelle observée entre deux comptes est improbable sous un modèle où les publications sont indépendantes conditionnellement aux images.

Cela permet d'identifier des comportements de coordination sans supposer de distribution paramétrique des temps de publication.

A.5.9 Erreur Monte Carlo

L'estimation de la p-value étant basée sur un nombre fini de permutations, elle est sujette à une erreur d'approximation appelée **erreur Monte Carlo**. Cette erreur peut être approximée par :

$$SE_{MC}(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{B}}$$


Dans le pire des cas, lorsque $\hat{p} = 0.5$, l'erreur Monte Carlo maximale est :

$$SE_{MAX} = \frac{1}{2\sqrt{B}}$$

Le nombre de permutations B peut être choisi de manière à contrôler cette erreur, en imposant :

$$SE_{MC}(\hat{p}) \leq SE_{MAX}.$$

A.5.10 Moyennes ergodiques des p-values



(a) 4 liens non significatifs ($\lambda = 0.05$)

(b) 4 liens significatifs ($\lambda = 0.5$)

FIGURE 21 – Analyse de la convergence des p-values estimées par permutation pour deux valeurs de λ (Cluster 01)

A.6 DÉTAILS SUPPLÉMENTAIRES SUR LA CORRECTION DES TESTS MULTIPLES

Dans cette étude, un grand nombre d'hypothèses statistiques est testé simultanément, chaque paire de comptes étant associée à une p-value issue du test de permutation. Lorsque le nombre de tests est élevé, il devient nécessaire de corriger les p-values afin de limiter le nombre de faux positifs.

La méthode retenue est la procédure de **Benjamini-Hochberg**, qui permet de contrôler le FDR, défini comme la proportion attendue de faux positifs parmi les hypothèses rejetées.

La FDR est définie par :

$$FDR = \mathbb{E} \left(\frac{V}{R} \right)$$

où :

- V représente le nombre de faux positifs,
- R représente le nombre total d'hypothèses rejetées.

Contrairement aux méthodes contrôlant le Family-Wise Error Rate (FWER), cette approche autorise une faible proportion d'erreurs afin de conserver une bonne capacité de détection lorsque le nombre de tests est important.

La procédure de Benjamini–Hochberg s'effectue comme suit.

A.6.1 Etape 1 - Tri des p-values

On considère les m p-values obtenues pour l'ensemble des tests et on les trie par ordre croissant :

$$P_{(1)} \leq P_{(2)} \leq \dots \leq P_{(m)}$$

A.6.2 Etape 2 - Comparaison avec les seuils BH

Pour chaque p-value ordonnée $P_{(i)}$, on compare sa valeur au seuil :

$$\frac{i}{m} \alpha$$

où :

- i est le rang de la p-value,
- m est le nombre total de tests,
- α est le niveau de significativité choisi.

A.6.3 Etape 3 - Recherche du rang critique

On identifie le plus grand indice k tel que :

$$P_{(k)} \leq \frac{k}{m} \alpha$$

A.6.4 Etape 4 - Rejet des hypothèses nulles

Toutes les hypothèses nulles associées aux p-values :

$$P_{(1)}, \dots, P_{(k)}$$

sont rejetées.

Dans ce cas, les k tests correspondants sont considérés comme statistiquement significatifs.

Sous l'hypothèse d'indépendance (ou de dépendance positive) entre les tests, cette procédure garantit que :

$$FDR \leq \alpha$$

Dans le cadre de notre analyse, seules les paires de comptes dont la p-value ajustée satisfait cette condition sont conservées pour construire le **sous-réseau de coordination statistiquement significatif**.

La figure 22 ci-après montre concrètement comment s'effectue le test multiple avec correction de la FDR. Le test multiple avec correction de la FDR a mis en exergue trois liens significatif alors que le test de Bonferroni avec un seuil de :

$$\alpha_{\text{Bonf}} = \frac{\alpha}{m} = \frac{0.05}{3} \approx 0.0167$$

stipule qu'**aucun lien ne serait retenu** (aucune p-value n'est inférieure à **0.0167**). Bonferroni est donc plus **conservateur** que Benjamini-Hochberg.

A.6.5 Exemple de l'extraction du sous réseau significatif via le modèle nul par permutation




FIGURE 22 – Etape d'extraction des comptes significativement coordonnés avec le modèle nul de permutation et la correction de la FDR

A.7 ALGORITHME DE LOUVAIN

Algorithm 1: Algorithme détaillé de détection de communautés Louvain

Input: $G = (U, E)$ graphe pondéré, matrice d'adjacence $A = (A_{ij})$

Output: Partition $\mathcal{P}$ maximisant la modularité Q

Étape 0 : Pré-calcul

Calculer les degrés pondérés des nœuds :

$$k_i = \sum_j A_{ij}$$

Calculer le poids total :

$$m = \frac{1}{2} \sum_{i,j} A_{ij}$$

Étape 1 : Initialisation

Attribuer à chaque nœud sa propre communauté :

$$\mathcal{P} = \{\{u_1\}, \{u_2\}, \dots, \{u_n\}\}$$

Étape 2 : Optimisation locale de la modularité

amélioration $\leftarrow$ vrai;

while amélioration **do**

 amélioration $\leftarrow$ faux;

foreach $u_i \in U$ **do**

 Soit C_{ancien} la communauté actuelle de u_i ;

 Retirer u_i de C_{ancien} ;

 meilleur_gain $\leftarrow$ 0;

 meilleure_communauté $\leftarrow C_{ancien}$;

foreach communauté C connectée à u_i **do**

 Calculer :

$$k_{i,in} = \sum_{u_j \in C} A_{ij}$$

$$\sum_{tot} = \sum_{u_j \in C} k_j$$

 Calculer le gain de modularité :

$$\Delta Q = \frac{k_{i,in}}{m} - \frac{k_i \cdot \sum_{tot}}{2m^2}$$

if $\Delta Q > meilleur_gain$ **then**

 meilleur_gain $\leftarrow \Delta Q$;

 meilleure_communauté $\leftarrow C$;

 Insérer u_i dans meilleure_communauté;

if meilleure_communauté $\neq C_{ancien}$ **then**

 amélioration $\leftarrow$ vrai;

Étape 3 : Agrégation des communautés

Construire un nouveau graphe G' :

 — Chaque communauté devient un super-nœud.

 — Le poids entre deux super-nœuds est égal à la somme des poids entre leurs nœuds constituants.

Étape 4 : Récursion

if le nombre de communautés a diminué **then**

 Appliquer Louvain sur G' ;

return $\mathcal{P}$

A.8 SÉLECTION DU SEUIL ET DE LA MÉTHODE POUR LA SUPPRESSION DES DOUBLONS

Entrée

Un ensemble de paires d'images annotées sous forme d'un tableau :

ImgA	ImgB	GroupA	GroupB	Label	Distance
A00	A01	C1	C1	1	d_1
A01	B00	C1	C2	0	d_2
A00	D00	C1	C3	0	d_3

où :

- $Label = 1$ signifie que les images sont des doublons
- $Label = 0$ signifie que les images sont différentes
- $Distance$ représente la distance de Hamming entre les deux images

Sortie

Seuil optimal T .

Algorithme**Étape 1 : Calculer les distances**

Pour chaque paire d'images :

$$d_i = d_H(\text{hash}(A_i), \text{hash}(B_i))$$

Stocker les distances dans un tableau.

Étape 2 : Séparer les distances

Créer deux ensembles :

Distances des doublons :

$$D_{pos} = \{d_i \mid label = 1\}$$

Distances des non-doublons :

$$D_{neg} = \{d_i \mid label = 0\}$$

Étape 3 : Trier les distances

Trier les distances dans l'ordre croissant.

Étape 4 : Déterminer le seuil

Choisir le seuil :

$$T = \max(D_{pos})$$

avec la condition :

$$P(d \in D_{neg} \leq T) \approx 0$$

c'est-à-dire qu'aucune distance de non-doublon ne doit être inférieure au seuil.

Étape 5 : Validation

Tester le seuil T sur un jeu de test :

- vérifier que les doublons sont détectés
- vérifier que les faux positifs sont proches de 0

A.9 OPTIMISATION BAYÉSIENNE : ALGORITHME

Algorithm 2: Optimisation Bayésienne des hyperparamètres UMAP + HDBSCAN**Input:** Données $\mathcal{D}$, espace des hyperparamètres $\mathcal{X}$, budget N , taille initiale n_0 **Output:** Meilleur ensemble d'hyperparamètres x^* **Définition de la fonction objectif**

Pour

$$x = (n_neighbors, n_components, min_cluster_size, min_dist, min_samples_ratio)$$

Définir :

$$f(x) = \text{DBCV}(\text{HDBSCAN}(\text{UMAP}(\mathcal{D}; x)))$$

Étape 0 : InitialisationÉchantillonner n_0 configurations x_i dans $\mathcal{X}$;

Évaluer :

$$y_i = f(x_i)$$

Construire :

$$\mathcal{D}_{n_0} = \{(x_i, y_i)\}_{i=1}^{n_0}$$

Étape 1 : Modélisation bayésienne

Placer un processus gaussien :

$$f \sim \mathcal{GP}(m(x), k(x, x'))$$

Étape 2 : Boucle séquentielle**for** $n = n_0, \dots, N - 1$ **do**

Mise à jour du posterior

$$f(x) \mid \mathcal{D}_n \sim \mathcal{N}(\mu_n(x), \sigma_n^2(x))$$

Fonction d'acquisition (EI pour maximisation)

Soit :

$$f^* = \max_{1 \leq i \leq n} y_i$$

$$z = \frac{\mu_n(x) - f^*}{\sigma_n(x)}$$

$$\alpha_n(x) = (\mu_n(x) - f^*)\Phi(z) + \sigma_n(x)\phi(z)$$

Sélection du prochain point

$$x_{n+1} = \arg \max_{x \in \mathcal{X}} \alpha_n(x)$$

Évaluation coûteuse

Calculer :

$$y_{n+1} = f(x_{n+1})$$

Mettre à jour :

$$\mathcal{D}_{n+1} = \mathcal{D}_n \cup \{(x_{n+1}, y_{n+1})\}$$

Sortie

$$x^* = \arg \max_{(x_i, y_i) \in \mathcal{D}_N} y_i$$